Estimation paramétrique ponctuelle & distribution d'échantillonnage

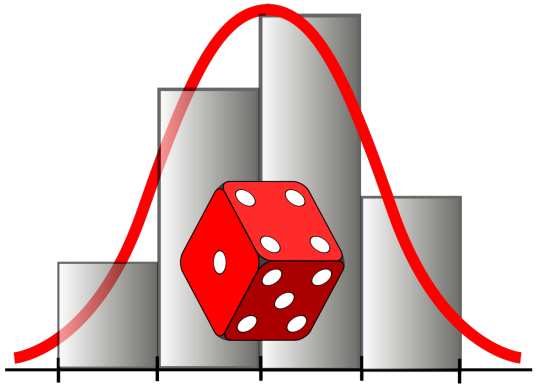

Module : Techniques d'estimation pour l'ingénieur

Plan

1. Introduction
   - Notion d'échantillonnage
   - Notion d'estimation paramétrique
2. Estimation paramétrique ponctuelle
   - Qualités des estimateurs
   - Méthodes d'estimation ponctuelle
     - Estimateur par méthode des moments (EMM)
     - Estimateur par la méthode du maximum de vraisemblance (EMV)
4. Distribution d'échantillonnage
   - Distribution échantillonnale de la moyenne $\overline{X_n}$
   - Distribution échantillonnale de la variance S_n^2
   - Distribution échantillonnale de la proportion F

Problématique ?

Question : combien y a-t-il de personnes atteintes de troubles de la vue parmi les conducteurs automobiles en Tunisie?

Réponse : 10%? 40%? 75%?

- Il est impossible de les compter toutes en examinant toute la population des conducteurs tunisiens.
- Il va être nécessaire d'utiliser une procédure particulière (l'échantillonnage) et des méthodes statistiques pour estimer la précision du résultat (incertitude) .

Terminologie

- **Population :** l'ensemble que l'on observe et qui sera soumis à une analyse statistique, chaque élément de cet ensemble est un individu ou unité statistique.
- **Echantillon :** Un sous-ensemble de la population étudiée.

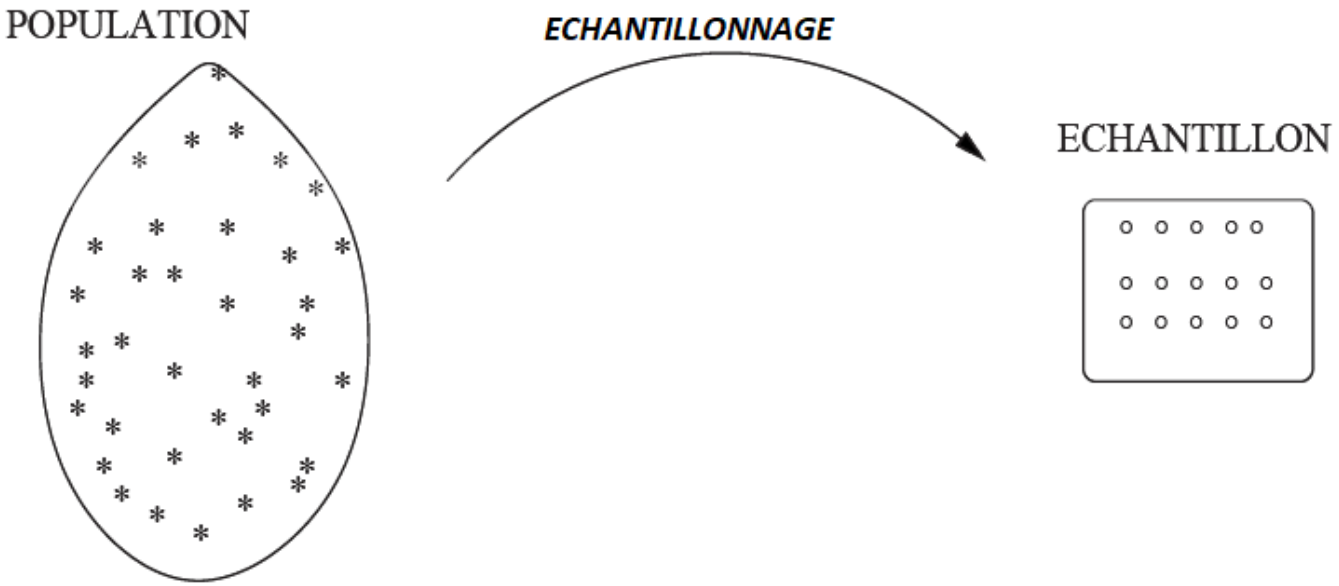

Pourquoi prendre un échantillon ?

- **Le coût :** analyser toute la population coûte trop cher.
- **Le temps :** on souhaite obtenir l'information le plus rapidement possible.
- **L'impossibilité :** lorsque la population est infinie.

Types d'échantillonnage

Les techniques d'échantillonnage peuvent être regroupées en deux grandes familles :

- Echantillonnage sur la base des méthodes empiriques :
  La méthode des quotas (se base sur la composition de la population pour certains critères) est la plus utilisée.
- Echantillonnage aléatoire simple :
  Tous les échantillons possibles de même taille ont la même probabilité d'être choisis et tous les éléments de la population ont une chance égale de faire partie de l'échantillon.

Contexte général

- Dans toute la suite du cours, on se place dans le cadre d'un échantillonnage aléatoire simple.
- On se propose d'étudier un caractère statistique X sur une population de taille N. On s'intéresse à la valeur inconnue d'un paramètre bien précis θ de la loi de X :
  - Si le caractère est quantitatif : Espérance, variance.
  - Si le caractère est qualitatif : Proportion.
- Si on prélève n individus dans cette population, on obtient n valeurs $x_1, x_2, \ldots, x_n$.
- L'observation x_i peut être considérée comme une observation d'une variable aléatoire X_i de même loi que X.

La situation peut être résumée par le schéma illustratif suivant :

Notion d'échantillonnage

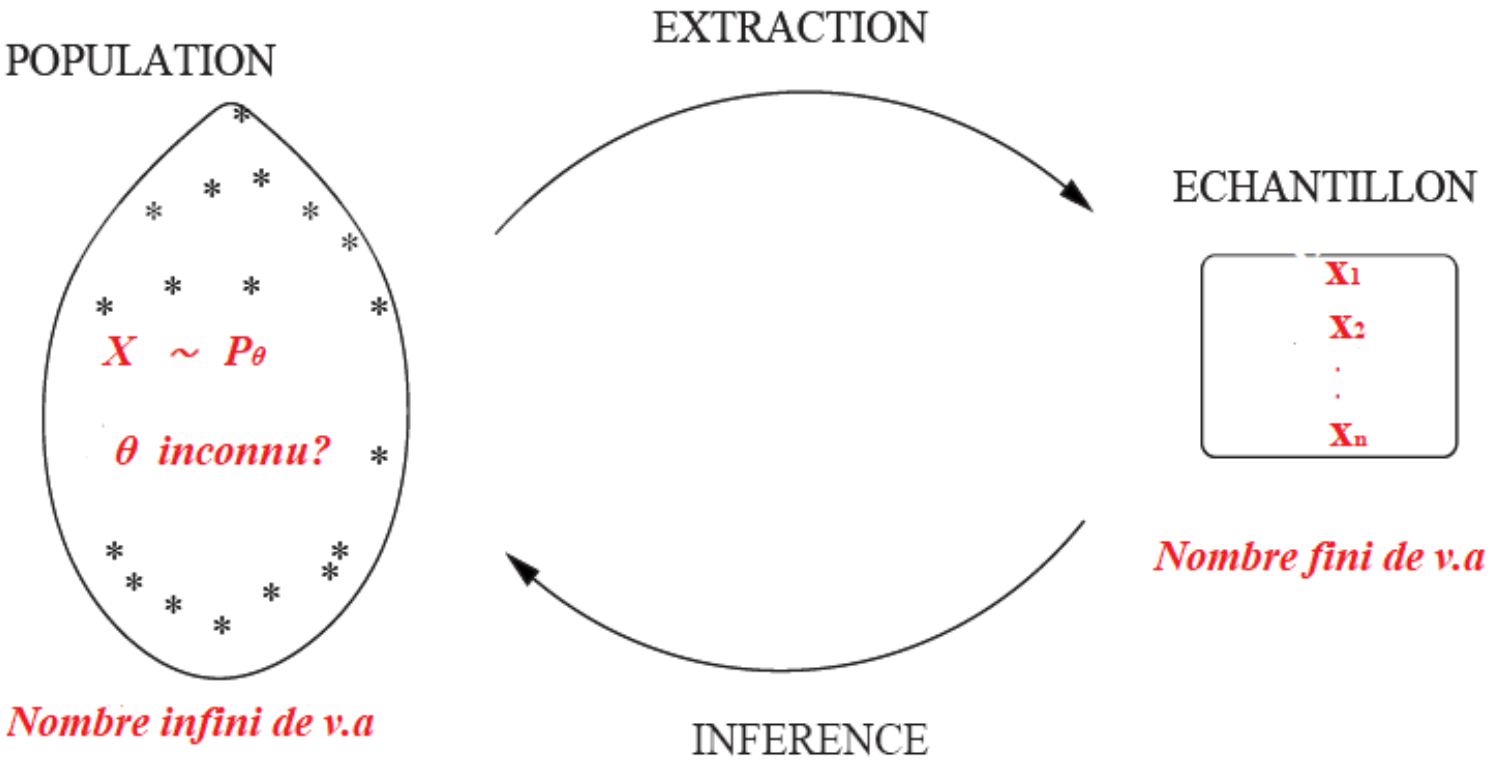

La stratégie consiste à utiliser l'information obtenue sur un échantillon de taille n pour déduire de l'information sur la population : on extrait un échantillon de la population, on l'analyse et on infère sur la population.

Notion d'échantillonnage

On décris habituellement un échantillon ou une population à l'aide de mesures telles que le nombre d'unité (la taille), la moyenne, l'écart-type et le pourcentage (proportion).

Les mesures qu'on utilise pour décrire une population sont **des paramètres**.

Un paramètre est une caractéristique de la population.

Les mesures qu'on utilise pour dérire un échantillon sont appelées **des statistiques**.

Une statistique est une caractérisatique de l'échantillon.

Activité introductive :

"Comment on peut vérifier expérimentalement qu'une pièce de monnaie est équilibrée ?"

On jette cette pièce de monnaie $n-$fois et on associe pour chaque lancée une variable aléatoire $X \sim \mathcal{B}(p)$: Bernoulli de paramètre $p \in]0,1[$.
La $i^{\text{ème}}$ lancée correspond à la variable aléatoire X_i définie comme suit:

$$X_i \sim \mathcal{B}(p) \quad \Longrightarrow \quad \begin{array}{c} \Omega \\ \left\{ \begin{array}{c} \omega_1 = P \\ \omega_2 = F \end{array} \right\} \end{array} \xrightarrow{X_i} \begin{array}{c} X_i(\omega) \\ \left\{ \begin{array}{c} 1 \\ 0 \end{array} \right\} \end{array} \quad ; \quad \forall 1 \leq i \leq n$$

Notion d'estimation Paramétrique

- Alors les X_i sont iid : indépendantes et de même loi que $X \sim \mathcal{B}(p)$.

C'est ainsi, afin de vérifier si cette pièce de monnaie est équilibrée ou non, il suffit de vérifier si $p = \frac{1}{2}$ ou non.
Comme l'inconnu p est l'espérance de la loi de Bernoulli, $X \sim \mathcal{B}(p)$;

$$\mathbb{E}[X] = p$$

L'idée ici est de l'estimer ou de l'approcher par la variable aléatoire suivante:

$$\frac{S_n}{n} = \frac{X_1(\omega) + X_2(\omega) + \cdots + X_n(\omega)}{n}$$

- Estimer un paramètre consiste à chercher une valeur approchée en se basant sur les résultats obtenus à partir d'un échantillon aléatoire.

Notion d'estimation paramétrique

Dans ce cours, on s'intéresse à estimer certaines caractéristiques statistiques (moyenne, variance, proportion) d'une certaine loi par différentes méthodes, où cette loi théorique on la connait mais on ignore son paramètre.

$\Longrightarrow$ C'est le cadre d'une **estimation paramétrique unidimensionnelle**.

On cite deux types d'estimations paramétriques:

- Estimation paramétrique ponctuelle : estimation est donnée par une seule valeur.
  - (E.M.M) La méthode des moments
  - (E.M.V) La méthode de maximum de vraisemblance
- Estimation paramétrique par intervalle de confiance.
  - Intervalle centré
  - Intervalle décentré

Définitions

Un échantillon de taille n (ou n-échantillon) est une famille $(X_1, \ldots, X_n)$ de variables aléatoires indépendantes et identiquement distribuées (i.i.d) de même loi $\mathbb{P}_\theta$.

Une réalisation de taille n (ou n-réalisation) d'un n-échantillon est le résultat de n tirages indépendants selon la loi de X_i, c'est une collection $(x_1, \ldots, x_n)$ de points de $\mathbb{R}$.

Estimation paramétrique ponctuelle

Lorsqu'un paramètre est estimé par un seul nombre, déduit des résultats de l'échantillon, ce nombre est appelé **estimation ponctuelle** du paramètre.

Estimateur

Soit $(X_1, \ldots, X_n)$ un n-échantillon de loi $\mathbb{P}_\theta$, $\theta \in \mathbb{R}$, et $(x_1, \ldots, x_n)$ une n-réalisation, on appelle:

- Une **statistique** toute fonction $g(X_1, \ldots, X_n)$ de l'échantillon avec $g : \mathbb{R}^n \to \mathbb{R}$ une fonction continue.
- Un **estimateur** de θ toute statistique utilisée pour estimer θ.
- Une **estimation** de θ toute fonction $g(x_1, \ldots, x_n)$ de la réalisation (observation) avec $g : \mathbb{R}^n \to \mathbb{R}$ une fonction continue.

Exemple N°1

Soit $(X_1, \ldots, X_n)$ un $n-$échantillon de loi de Bernoulli $\mathcal{B}(p)$ et $(0, 1, 1, 0, \ldots, 1)$ une $n-$réalisation alors :

$$\widehat{P}_n = \frac{X_1 + \ldots + X_n}{n} \quad \text{est un estimateur de p}$$

$$\tilde{p}_n = \frac{0+1+1+0+\ldots+1}{n} \quad \text{est une estimation de p}$$

$\Longrightarrow$ Évidemment l'estimateur $\widehat{P}_n$ de p est une statistique permettant d'évaluer le paramètre inconnu p relatif à la loi de probabilité parente $\mathcal{B}(p)$.

Estimation paramétrique ponctuelle

Un paramètre inconnu θ peut avoir plusieurs estimateurs, par exemple pour estimer le paramètre m moyenne d'une population, on pourrait se servir de :

- la moyenne arithmétique
- la médiane
- le mode

C'est pourquoi on doit choisir le meilleur estimateur de θ parmi tous ses estimateurs, autrement dit on doit choisir celui qui s'approche le plus possible de θ.
Divers propriétés peuvent être citées et elles servent à mesurer la qualité de l'estimateur choisi :

Estimateur sans biais

Soit θ_n un estimateur de $\theta \in \mathbb{R}$ telque $\mathbb{E}_\theta(\theta_n) < \infty$.
On appelle **biais** de θ_n par rapport à θ, le réel défini par:

$$\mathbb{E}_\theta(\theta_n - \theta) = \mathbb{E}_\theta(\theta_n) - \theta.$$

On dit que θ_n est un estimateur **sans biais** (ou bien **non biaisé**) de θ si

$$\mathbb{E}_\theta(\theta_n) = \theta$$

sinon, on dit qu'il est **avec biais** (ou bien **biaisé**).

Le biais mesure le décalage en moyenne entre les valeurs prises par l'estimateur et la vraie valeur du paramètre.

Exemple N°2

Considérons une variable aléatoire X suivant une loi $\mathbb{P}_\theta$ dans une population donnée.

Soit $(X_1, \ldots, X_n)$ un n-échantillon de taille n regroupant un ensemble de variables aléatoires indépendantes et identiquement distribuées, de même loi $\mathbb{P}_\theta$ que X, $\theta \in \mathbb{R}$, et $\mathbb{E}_\theta[X] < \infty$.

En se basant sur l'exemple 1 de l'activité introductive, nous déduisons que la variable aléatoire définie par:

$$\frac{S_n}{n} = \frac{X_1 + \ldots + X_n}{n}$$

est un estimateur sans biais de $\mathbb{E}_\theta[X]$.

En effet:

$$\begin{aligned}
\mathbb{E}[\frac{S_n}{n}] &= \mathbb{E}[\frac{1}{n}.\sum_{i=1}^{n} X_i] \\
&= \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[X_i] \quad \text{(Comme l'espérance est linéaire)} \\
&= \frac{1}{n}.\ n.\ \mathbb{E}[X_1] \quad \text{(Les } X_i \text{ sont iid)} \\
&= \mathbb{E}_\theta[X] \quad \text{(Les } X_i \text{ sont de même loi que X)}
\end{aligned}$$

Cette variable est dite **moyenne empirique** et elle est notée $\overline{X_n}$.

$$\overline{X_n} := \frac{1}{n}\sum_{i=1}^{n} X_i$$

Exemple N°3

Considérons une variable aléatoire X suivant une loi $\mathbb{P}$ dans une population donnée.
Soit $(X_1, X_2, .., X_n)$ un n-échantillon de taille n regroupant un ensemble de variables aléatoires indépendantes et identiquement distribuées, de même loi $\mathbb{P}$ que X. Avec:

$$\mathbb{E}[X] = \theta \quad ; \quad Var[X] = \sigma^2_{pop}$$

On se propose d'estimer la variance dans la population par la v.a suivante:

$$\sigma^2_{ech} := \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2$$

σ^2_{ech} est-il avec ou sans biais?

Estimation paramétrique ponctuelle

D'abord, on a :

$$\begin{aligned}
\sigma^2_{ech} &= \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(X_i^2 - 2X_i\overline{X_n} + \overline{X_n}^2) \\
&= \frac{1}{n}[\sum_{i=1}^{n}X_i^2 - 2\overline{X_n}\sum_{i=1}^{n}X_i + \sum_{i=1}^{n}\overline{X_n}^2] \\
&= \frac{1}{n}\sum_{i=1}^{n}X_i^2 - \frac{2}{n}.\overline{X_n}.\sum_{i=1}^{n}X_i + \frac{1}{n}\sum_{i=1}^{n}\overline{X_n}^2
\end{aligned}$$

Or ; $\sum_{i=1}^{n}X_i = n\overline{X_n}$, alors

$$\sigma^2_{ech} = \frac{1}{n}\sum_{i=1}^{n}X_i^2 - 2\overline{X_n}^2 + \frac{1}{n}.n.\overline{X_n}^2 = \frac{1}{n}\sum_{i=1}^{n}X_i^2 - \overline{X_n}^2$$

Estimation paramétrique ponctuelle

Question : σ^2_{ech} est-il un estimateur sans biais de σ^2_{pop} ?

Pour répondre à cette question, calculons:

$$\begin{aligned}
\mathbb{E}[\sigma^2_{ech}] &= \mathbb{E}\big[\frac{1}{n}\sum_{i=1}^{n} X_i^2 - \overline{X_n}^2\big] \\
&= \frac{1}{n}\mathbb{E}\big[\sum_{i=1}^{n} X_i^2\big] - \mathbb{E}\big[\overline{X_n}^2\big] \\
&= \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}\big[X_i^2\big] - \mathbb{E}\big[\overline{X_n}^2\big] \quad \text{(L'espérance est linéaire)}
\end{aligned}$$

Comme :

$$\mathbb{V}[X] = \mathbb{E}\big[X^2\big] - \mathbb{E}\big[X\big]^2$$

$$\mathbb{E}[\sigma^2_{ech}] = \frac{1}{n}\sum_{i=1}^{n}[\mathbb{V}[X_i] + \mathbb{E}\big[X_i\big]^2] - [\mathbb{V}[\overline{X_n}] + \mathbb{E}\big[\overline{X_n}^2\big]]$$

Estimation paramétrique ponctuelle

$$
\begin{aligned}
\mathbb{E}[\sigma^2_{ech}] &= \frac{1}{n}\sum_{i=1}^{n}[\sigma^2_{pop} + m^2] - [\frac{\sigma^2_{pop}}{n} + m^2] \\
&= \frac{1}{n}.n[\sigma^2_{pop} + m^2] - [\frac{\sigma^2_{pop}}{n} + m^2] \\
&= \sigma^2_{pop} - \frac{\sigma^2_{pop}}{n} \\
&= \sigma^2_{pop}.\frac{n-1}{n} \neq \sigma^2_{pop}
\end{aligned}
$$

Donc la v.a σ^2_{ech} dite **variance empirique** de l'échantillon, est clairement un estimateur biaisé du paramètre σ^2_{pop}.
C'est pour cette raison qu'on va considérer la statistique (v.a) suivante:

$$S_n^2 := \frac{n}{n-1}\sigma^2_{ech} = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2$$

dite **variance empirique corrigée** de l'échantillon, qui est clairement un estimateur sans biais de σ^2_{pop}, puisque

$$\begin{aligned}\mathbb{E}[S_n^2] &= \mathbb{E}[\frac{n}{n-1}\sigma^2_{ech}] \\ &= \frac{n}{n-1}\mathbb{E}[\sigma^2_{ech}] \\ &= \frac{n}{n-1}.\frac{n-1}{n}\sigma^2_{pop} = \sigma^2_{pop}\end{aligned}$$

Estimateur asymptotiquement sans biais

Un estimateur $(\theta_n)_{n\geq 1}$ de θ est appelé estimateur **asymptotiquement sans biais** de $\theta \in \mathbb{R}$ si:

$$\lim_{n\to+\infty} \mathbb{E}_\theta[\theta_n - \theta] = \lim_{n\to+\infty} [\mathbb{E}_\theta(\theta_n) - \theta] = 0$$

Attention

L'absence de biais, toute seule, ne garantit pas que nous avons un bon estimateur. Il est tout à fait possible qu'un estimateur biaisé soit meilleur qu'un estimateur non biaisé.

Le choix entre les estimateurs s'effectue en comparant ce qu'on appellera le **risque quadratique** :

Estimateur meilleur

Soit θ_n un estimateur de $\theta \in \mathbb{R}$ admettant un moment d'ordre 2.
On appelle le **risque quadratique** de l'estimateur θ_n la fonction R_{θ_n} définie par:

$$R_{\theta_n}(\theta) = \mathbb{E}_\theta\left((\theta_n - \theta)^2\right)$$

- Un estimateur θ_n de θ est dit **meilleur** qu'un autre estimateur T_n de θ si et seulement si

$$R_{\theta_n}(\theta) \leq R_{T_n}(\theta).$$

Estimateur convergent

Soit $(\theta_n)_{n\geq 1}$ une famille d'estimateurs de $\theta \in \mathbb{R}$ admettant un moment d'ordre 2, $(\theta_n)_{n\geq 1}$ est dite **convergente** (dite aussi consistante) si:

$$\lim_{n\to+\infty} \mathbb{V}_\theta(\theta_n) = 0$$

Remarque

Si deux estimateurs sont convergents et sans biais, le meilleur est celui qui a **la variance la plus faible** car ses valeurs sont en moyenne plus proches de la quantité estimée:

Estimateur de variance minimale

Un estimateur sans biais et admettant un moment d'ordre 2 est dit de **variance minimale** si sa variance est la plus faible parmi les variances des autres estimateurs sans biais.

Ainsi, si $\hat{\theta}_1$ et $\hat{\theta}_2$ sont deux estimateurs sans biais du paramètre θ, l'estimateur $\hat{\theta}_1$ est de variance minimale si et seulement si

$$\mathbb{V}_\theta(\hat{\theta}_1) < \mathbb{V}_\theta(\hat{\theta}_2) \text{ et } \mathbb{E}_\theta(\hat{\theta}_1) = \mathbb{E}_\theta(\hat{\theta}_2) = \theta$$

Exercice N°1:

Soit $(X_1, \ldots, X_n)$ un $n-$échantillon d'une v.a. $X \sim \mathcal{U}([0, \theta])$, où θ est un paramètre strictement positif inconnu. Soit $\hat{\theta}_n = \underset{1 \leq i \leq n}{max} X_i$ un estimateur de θ.

1. Montrer que $\mathbb{E}_\theta[\hat{\theta}_n] = \frac{n}{n+1}\theta$
2. Montrer que $\tilde{\theta}_n = 2\bar{X}_n$ est un estimateur sans biais de θ.
3. Montrer que $\hat{\theta}_n$ est meilleur que $\tilde{\theta}_n$.

Solution

$(X_1, \ldots, X_n)$ un $n-$échantillon d'une v.a. $X \sim \mathcal{U}([0, \theta])$, où θ est un paramètre strictement positif inconnu.

Rappel

X $\sim \mathcal{U}([0, \theta])$, alors $\mathbb{E}[X] = \frac{\theta}{2}$; $Var[X] = \frac{\theta^2}{12}$

$$f(x) = \begin{cases} \frac{1}{\theta} & si \quad x \in [0, \theta], \\ 0 & \quad sinon. \end{cases}$$

$$F(x) = \begin{cases} 0 & si \quad x < 0, \\ \frac{x}{\theta} & si \quad x \in [0, \theta], \\ 1 & si \quad x > \theta. \end{cases}$$

1. Montrons que $\mathbb{E}_\theta[\hat{\theta}_n] = \frac{n}{n+1}\theta$:

$$\mathbb{E}_\theta[\hat{\theta}_n] = \int_{\mathbb{R}} t.f_{\hat{\theta}_n}(t).dt$$

Donc, on cherche en premier lieu $f_{\hat{\theta}_n}$:

$$\begin{aligned}
F_{\hat{\theta}_n}(t) &= \mathbb{P}(\hat{\theta}_n \leq t) \\
&= \mathbb{P}(\max_{1\leq i\leq n} X_i \leq t) \\
&= \mathbb{P}\big((X_1 \leq t) \cap (X_2 \leq t) ... \cap (X_n \leq t)\big) \\
&= \mathbb{P}(X_1 \leq t).\mathbb{P}(X_2 \leq t)...\mathbb{P}(X_n \leq t) \quad (\textit{les } X_i \textit{ sont iid}) \\
&= \prod_{i=1}^{n} \mathbb{P}(X_i \leq t) = (F_{X_1}(t))^n
\end{aligned}$$

et par la suite, trouver $f_{\hat{\theta}_n}$ revient à dériver $(F_{X_1}(t))^n$:

$$\begin{aligned}
\frac{d}{dt}(F_{X_1}(t))^n &= n\ .\ F'_{X_1}(t).(F_{X_1}(t))^{n-1} \\
&= n.\ f_{X_1}(t)\ .\ (F_{X_1}(t))^{n-1} \quad (X_1 \sim \mathcal{U}([0,\theta])) \\
&= \begin{cases} \frac{n}{\theta}\frac{t^{n-1}}{\theta^{n-1}} = \frac{nt^{n-1}}{\theta^n} & si \quad t \in [0,\theta], \\ 0 & sinon. \end{cases}
\end{aligned}$$

On revient maintenant à l'espérance:

$$\begin{aligned}
\mathbb{E}_\theta[\hat{\theta}_n] &= \int_{\mathbb{R}} t.f_{\hat{\theta}_n}(t).dt \\
&= \int_0^\theta t.f_{\hat{\theta}_n}(t).dt \\
&= \int_0^\theta t.\frac{nt^{n-1}}{\theta^n}dt \\
&= \frac{n}{\theta^n}\int_0^\theta t^n.dt
\end{aligned}$$

$$\mathbb{E}_\theta[\hat{\theta}_n] = \frac{n}{\theta^n}\left[\frac{t^{n+1}}{n+1}\right]_0^\theta = \frac{n}{n+1}\theta$$

2. Montrons que $\tilde{\theta}_n = 2\bar{X}_n$ est un estimateur sans biais de θ.
   Calculons $\mathbb{E}[\tilde{\theta}_n]$?

$$\begin{aligned}
\mathbb{E}[\tilde{\theta}_n] &= \mathbb{E}[2\bar{X}_n] \\
&= 2.\mathbb{E}[\bar{X}_n] \\
&= 2.\mathbb{E}[\frac{1}{n}\sum_{i=1}^{n} X_i] \\
&= \frac{2}{n}.n.\ \mathbb{E}[X_1] \\
&= 2\frac{\theta}{2} = \theta
\end{aligned}$$

Conclusion : $\tilde{\theta}_n$ est un estimateur sans biais de θ.

1. Remarque

   Le fait que $\hat{\theta}_n$ est un estimateur biaisé alors que $\tilde{\theta}_n$ ne l'est pas, n'implique pas que $\tilde{\theta}_n$ est meilleur que $\hat{\theta}_n$.

   Il est possible de trouver des estimateurs biaisés plus précis que des estimateurs non biaisés.

   Comparaison de $\tilde{\theta}_n$ et $\hat{\theta}_n \Longrightarrow$ On compare le risque quadratique :

On calcule d'abord le risque quadratique de $\tilde{\theta}_n$:

$$\begin{aligned} R_{\tilde{\theta}_n}(\theta) &= \mathbb{E}[(\tilde{\theta}_n - \theta)^2] \\ &= \mathbb{E}[(\tilde{\theta}_n - \mathbb{E}[\tilde{\theta}_n])^2] \\ &= Var[\tilde{\theta}_n] \\ &= Var[2.\bar{X}_n] \\ &= Var[\frac{2}{n}\sum_{i=1}^{n} X_i] \end{aligned}$$

$$
\begin{aligned}
R_{\tilde{\theta}_n}(\theta) &= \frac{4}{n^2}.n.Var[X_1] \\
&= \frac{4}{n}\frac{\theta^2}{12} \\
&= \frac{\theta^2}{3n}
\end{aligned}
$$

On calcule maintenant le risque quadratique de $\hat{\theta}_n$:

$$
\begin{aligned}
R_{\hat{\theta}_n}(\theta) &= \mathbb{E}[(\hat{\theta}_n - \theta)^2] \\
&= \underbrace{\mathbb{E}[\hat{\theta}_n^2]}_{?} - 2\mathbb{E}[\hat{\theta}_n].\theta + \theta^2
\end{aligned}
$$

Or

$$\begin{aligned}\mathbb{E}[\hat{\theta}_n^2] &= \int_0^\theta t^2.n.\frac{t^{n-1}}{\theta^n}.dt \\ &= \frac{1}{\theta^n}\int_0^\theta t^{n+1}.dt \\ &= \frac{n}{\theta^n}\Big[\frac{t^{n+2}}{n+2}\Big]_0^\theta \\ &= \frac{n}{n+2}\theta^2\end{aligned}$$

Alors :

$$R_{\hat{\theta}_n}(\theta) = \frac{n}{n+2}\theta^2 - \frac{2n}{n+1}\theta^2 + \theta^2 = \frac{2\theta^2}{(n+2)(n+1)}$$

Conclusion :

$$R_{\hat{\theta}_n}(\theta) - R_{\tilde{\theta}_n}(\theta) = \frac{2\theta^2}{(n+2)(n+1)} - \frac{\theta^2}{3n} \leq 0$$

$R_{\hat{\theta}_n}(\theta) \leq R_{\tilde{\theta}_n}(\theta) \Longrightarrow \hat{\theta}_n$ est meilleur que $\tilde{\theta}_n$.

Méthodes d'estimation ponctuelle

- Estimation par méthode des moments (E.M.M)

L'idée de base de cette méthode est d'utiliser les moments d'ordre 1 et 2:

-**Moment d'ordre** 1 pour estimer la moyenne $\mathbb{E}_\theta(X)$ par une moyenne empirique :

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$$

-**Moment non centré d'ordre** 2 pour estimer $\mathbb{E}_\theta(X^2)$ par :

$$\overline{X_n^2} = \frac{1}{n}\sum_{k=1}^{n} X_k^2$$

-**Moment centré d'ordre** 2 pour estimer la variance $\mathbb{V}_\theta(X)$ par une variance empirique :

$$\overline{X_n^2} - (\overline{X}_n)^2 = \frac{1}{n}\sum_{k=1}^{n} X_k^2 - (\overline{X}_n)^2$$

Méthodes d'estimation ponctuelle

Si le paramètre à estimer est l'espérance de la loi des X_i, alors on peut l'estimer par la moyenne empirique de l'échantillon.
Autrement dit, si $\theta = \mathbb{E}(X)$, alors l'estimateur de θ par la méthode des moments (E.M.M) est :

$$\widehat{\theta}_n = \overline{X_n} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Plus généralement, pour $\theta \in \mathbb{R}$, si $\mathbb{E}_\theta[X] = \varphi(\theta)$, où φ est une fonction bijective, alors l'estimateur de θ par la méthode des moments est

$$\widehat{\theta}_n = \varphi^{-1}(\overline{X_n})$$

Exemple N°1:

Soit $(X_1, \ldots, X_n)$ un $n-$échantillon qui suit la loi exponentielle de paramètre $\lambda > 0$. Déterminer l'estimateur de λ par la méthode des moments.

Solution

$\mathbb{E}_\lambda(X_1) = \frac{1}{\lambda} = \varphi(\lambda)$, avec :

$$\begin{cases} \varphi(t) = \frac{1}{t} \\ \\ \varphi^{-1}(t) = \frac{1}{t} \end{cases}$$

et par la suite l'estimateur de θ par la méthode des moments est

$$\widehat{\lambda} = \varphi^{-1}(\overline{X_n}) = \frac{1}{\overline{X}_n}$$

Exemple N°2 :

Soit $(X_1, \ldots, X_n)$ un $n-$échantillon qui suit la loi uniforme $\mathcal{U}([0, \theta])$. Déterminer l'estimateur de θ par la méthode des moments.

Solution

$\mathbb{E}_\theta(X_1) = \frac{\theta}{2} = \varphi(\theta)$, avec :

$$\begin{cases} \varphi(t) = \frac{t}{2} \\ \\ \varphi^{-1}(t) = 2t \end{cases}$$

et par la suite l'estimateur de θ par la méthode des moments est

$$\widehat{\theta} = \varphi^{-1}(\overline{X_n}) = 2\overline{X}_n$$

- Estimation par la méthode du maximum de vraisemblance (E.M.V)

Soit $(X_1, \ldots, X_n)$ un $n-$échantillon de loi $\mathbb{P}_\theta$ (discrète ou continue), avec $\theta \in \mathbb{R}$ un paramètre inconnu qu'on cherche à estimer.
On vise maintenant à définir l'estimateur du maximum de vraisemblance de θ, pour cela on a besoin d'introduire la notion de la fonction de vraisemblance associée à un échantillon :

Fonction de vraisemblance

La fonction de vraisemblance de θ pour une réalisation $(x_1, \ldots, x_n)$ d'un échantillon $(X_1, \ldots, X_n)$ est l'application $L(x_1, \cdots, x_n; \bullet) : \mathbb{R} \mapsto \mathbb{R}_+^*$ définie par, si X est:

Une variable aléatoire discrète: la loi de X est caractérisée par $\mathbb{P}_\theta$

$$L(x_1, \ldots, x_n; \theta) = \prod_{i=1}^{n} \mathbb{P}_\theta(X_i = x_i),$$

Une variable aléatoire continue: la loi de X est caractérisée par f_θ

$$L(x_1, \ldots, x_n; \theta) = \prod_{i=1}^{n} f_\theta(x_i),$$

Exemple

On considère un échantillon $\{X_1\}$ de taille $n = 1$. On suppose que $X_1 \sim \mathcal{B}(15, p)$, avec p inconnu. On observe $x_1 = 5$ et on cherche à estimer p.

1. Déterminer la fonction de vraisemblance $L(5; p)$.
2. Donner les valeurs particulières de L pour $p \in \{0.1, 0.2, 0.3, \ldots, 0.9\}$.
3. Déterminer la valeur la plus vraisemblable de p.

Solution

Rappel

La loi de probabilité de la loi Binomiale $\mathcal{B}(n, p)$:

$$\mathbb{P}(X = k) = C_n^k p^k (1-p)^{n-k}$$

Dans notre cas, $n = 15$:

$$\mathbb{P}(X = k) = C_{15}^k p^k (1-p)^{15-k}$$

1. La fonction de vraisemblance $L(5, p)$ est donnée par :

$$L(5, p) = \prod_{i=1}^{n} \mathbb{P}(X_i = x_i)$$

$$= \mathbb{P}(X_1 = x_1)$$
$$= \mathbb{P}(X_1 = 5)$$

Par la suite :

$$L(5, p) = C_{15}^{5} p^5 (1-p)^{10}$$

2. Donons les valeurs particulières de L pour $p \in \{0.1, 0.2, 0.3, \ldots, 0.9\}$
   - $L(5; 0.1) = C_{15}^{5}(0.1)^5(1-0.1)^{10} = 0.104$
   - $L(5; 0.2) = C_{15}^{5}(0.2)^5(1-0.2)^{10} = 0.103$
   - $L(5; 0.3) = C_{15}^{5}(0.3)^5(1-0.3)^{10} = 0.206$
   - $L(5; 0.4) = C_{15}^{5}(0.4)^5(1-0.4)^{10} = 0.185$
   - $L(5; 0.5) = C_{15}^{5}(0.5)^5(1-0.5)^{10} = 0.091$

- $L(5; 0.6) = C_{15}^{5}(0.6)^5(1-0.6)^{10} = 0.024$
- $L(5; 0.7) = C_{15}^{5}(0.7)^5(1-0.7)^{10} = 0.029$
- $L(5; 0.8) = C_{15}^{5}(0.8)^5(1-0.8)^{10} = 0.002$
- $L(5; 0.9) = C_{15}^{5}(0.9)^5(1-0.9)^{10} = 0.17.10^{-5}$

3. La valeur la plus vraisemblable (probable) de p est celle pour laquelle la probabilité d'observer 5 est maximale,
   $\Longrightarrow L(5; 0.3) = 0.206$ pour la valeur $p = 0.3$.
   C'est la valeur de p qui maximise la fonction de vraisemblance.

Ceci revient donc à chercher le maximum de la fonction de vraissemblance (dérivée première s'annule et dérivée seconde négative), mais comme la vraissemblance est un produit, alors il devient plus commode de maximiser une somme qu'un produit en passant à la fonction logarithme de la vraissemblance.

De plus le fait que la valeur qui rend maximale une fonction rend aussi maximal son logarithme, nous permet de maximiser finalement le logarithme de la fonction de vraisemblance, qu'on appelle la **log-vraisemblance**.

Dans notre cas :

Méthodes d'estimation ponctuelle

La fonction de vraisemblance est :

$$L(5,p) = C_{15}^{5} p^{5} (1-p)^{10}$$

Sa fonction Logarithme est donnée par:

$$\begin{aligned} ln\big(L(x_1;p)\big) &= ln\big((C_{15}^{5} p^{5} (1-p)^{10})\big) \\ &= ln(C_{15}^{5}) + 5.ln(p) + 10.ln(1-p) \end{aligned}$$

Pour trouver la valeur qui maximise la log-vraisemblance, on calcule sa dérivée partielle par rapport à p :

$$\frac{d}{dp} Ln(L(5,p)) = 0 + \frac{5}{p} - \frac{10}{1-p}$$

Méthodes d'estimation ponctuelle

Le maximum est atteint quand cette dérivée partielle est nulle:

$$\frac{5}{p} - \frac{10}{1-p} = 0$$
$$\frac{5}{p} = \frac{10}{1-p}$$

Ce qui implique

$$p = \frac{5}{15} = \frac{1}{3}$$
$$\simeq 0.3$$

et pour cette valeur on a :

$$\frac{d^2}{d^2 p} Ln(L(5,p))_{|p=0.3} < 0$$

Estimateur du maximum de vraisemblance

Soit $L(x_1, \cdots, x_n; \bullet)$ la fonction de vraisemblance associée à la réalisation $(x_1, \ldots, x_n)$ de l'échantillon $(X_1, \ldots, X_n)$ qui suit la loi $\mathcal{L}_\theta$.
On appelle estimateur du maximum de vraisemblance (E.M.V) de θ la variable aléatoire correspondante à la valeur $\widehat{\theta}_n$ pour laquelle la fonction de vraisemblance atteint son maximum. Ce qui donne que $\widehat{\theta}_n$ l'estimateur de maximum de vraisemblance de θ est solution du système:

$$\begin{cases} \frac{dL}{d\theta}_{|\widehat{\theta}_n} = 0 \\ \\ \frac{d^2L}{d\theta^2}_{|\widehat{\theta}_n} < 0 \end{cases} \Leftrightarrow \begin{cases} \frac{d\ln L}{d\theta}_{|\widehat{\theta}_n} = 0 \\ \\ \frac{d^2\ln L}{d\theta^2}_{|\widehat{\theta}_n} < 0 \end{cases}$$

Exercice

Soit $(X_1, \ldots, X_n)$ un $n-$échantillon qui suit la loi exponentielle de paramètre $\frac{1}{\theta}$ avec $\theta > 0$, i.e. la fonction densité de probabilité est donnée par:

$$f(x) = \begin{cases} \frac{1}{\theta}\, e^{-\frac{x}{\theta}} & \text{si } x \geq 0 \\ 0 & \text{sinon} \end{cases}$$

1. Donner la fonction de vraisemblance associée à une réalisation $(x_1, \ldots, x_n)$ de l'échantillon.
2. Déterminer un estimateur $\widehat{\theta}_n$ de θ par la méthode du maximum de vraisemblance.

Solution

1. La fonction de vraisemblance :

$$L(x_1, x_2, ..., x_n; \theta) = \prod_{i=1}^{n} f_\theta(x_i) = \frac{1}{\theta^n} \prod_{i=1}^{n} e^{-\frac{x}{\theta}} = \begin{cases} \frac{1}{\theta^n}.e^{-\frac{\sum_i^n x_i}{\theta}} & ; \quad x \geq 0 \\ 0 & ; \quad \text{sinon} \end{cases}$$

2. Comme il est plus commode de maximiser une somme qu'un produit, on applique le logarithme:

$$\begin{aligned} ln\big(L(x_1, x_2, .., x_n; \theta)\big) &= ln(\frac{1}{\theta^n} e^{-\frac{\sum_i^n x_i}{\theta}}) \quad ; \quad x \geq 0 \\ &= ln(\frac{1}{\theta^n}) + ln(e^{-\frac{\sum_i^n x_i}{\theta}}) \\ &= -nln(\theta) - \frac{1}{\theta} \sum_{i=1}^{n} x_i \end{aligned}$$

Méthodes d'estimation ponctuelle

Vu que la valeur qui maximise une fonction , maximise aussi son logarithme, $\hat{\theta}_n$, l'estimateur du maximum de vraisemblance de θ est la variable aléatoire correspondante à la solution du système:

$$\begin{cases} \frac{d \ln L}{d\theta}_{|\widehat{\theta}_n} = 0 \\ \\ \frac{d^2 \ln L}{d\theta^2}_{|\widehat{\theta}_n} < 0 \end{cases}$$

$$\begin{aligned} \frac{d \ \ln \ L}{d\theta} = 0 &\Leftrightarrow -\frac{n}{\theta} + \frac{1}{\theta^2}\sum_{i=1}^{n} x_i = 0 \\ &\Leftrightarrow -\frac{n\theta}{\theta^2} + \frac{\sum_{i=1}^{n} x_i}{\theta^2} = 0 \\ &\Leftrightarrow \frac{-n\theta + \sum_{i=1}^{n} x_i}{\theta^2} = 0 \end{aligned}$$

$$\Leftrightarrow -n\theta + \sum_{i=1}^{n} x_i = 0$$

$$\Leftrightarrow \theta = \frac{\sum_{i=1}^{n} x_i}{n}$$

Donc la v.a associée à cette valeur de θ est donnée par :

$$\hat{\theta}_n = \overline{X_n}$$

Vérifions maintenant que :

$$\frac{d^2 \ln L}{d\theta^2}_{|\widehat{\theta}_n} < 0$$

On a :

$$\frac{d^2 \ln L}{d\theta^2} = \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^{n} x_i$$

Remplacons θ par $\widehat{\theta}_n$:

$$\frac{d^2 \ln L}{d\theta^2}_{|\widehat{\theta}_n=\overline{X_n}} = \frac{n}{\overline{X_n}^2} - \frac{2n\overline{X}_n}{\overline{X_n}^3}$$
$$= -\frac{n}{\overline{X_n}^2} < 0$$

Concclusion: $\widehat{\theta}_n$ est bien un estimateur de maximum de vraisemblance de θ.

Contexte général

En statistique, on décrit un échantillon ou une population à l'aide des mesures ou caractéristiques telles que la moyenne, l'écart-type, le pourcentage. De ce fait, s'il s'agit d'un :

-**Caractère quantitatif:** on estimera la moyenne μ et l'écart type σ d'une population.

-**Caractère qualitatif:** on estimera la proportion p de la population.

Les estimateurs ponctuels considerés pour l'estimation des paramètres inconnus : l'espérance μ , la variance σ^2 et la proportion p sont bien évidemment des variables aléatoires (statistiques) dont ils possèdent leurs propres lois (distributions).
On rappelle par la suite ces estimateurs ponctuels :

Distribution échantillonnale

A retenir

Soit $(X_1, \ldots, X_n)$ un échantillon de taille $n > 1$, qui suit une loi $\mathbb{P}$ (quelconque) d'espérance μ et de variance σ^2, et soit $(x_1, \ldots, x_n)$ une réalisation de cet échantillon.

- $\overline{X}_n := \frac{X_1 + \ldots + X_n}{n}$: **moyenne empirique** qui est un estimateur de m, son estimation $\overline{x}_n$ est la moyenne observée dans une réalisation de l'échantillon .
- $S_n^2 := \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X}_n)^2$: **variance empirique corrigée** qui est un estimateur de variance observée dans une réalisation de l'échantillon.
- $\hat{p}_n := \frac{X_1 + \ldots + X_n}{n}$: **proportion empirique** (notée aussi F) est un estimateur de la proportion p, avec $p \in]0, 1[$ représente la fréquence d'apparition d'un caractère qualitatif dans la population (ce caractère on le modèlise à chaque fois par la variable aléatoire $X_i \sim \mathcal{B}(p)$).

Loi de la moyenne empirique $\overline{X}_n$

On a défini une variable aléatoire qui à chaque $n-$échantillon associe sa moyenne échantillonnnale. On la note $\overline{X}_n$.
On cherche à caractériser la variable aléatoire $\overline{X}_n$ par :

- Sa moyenne.
- Sa variance.
- Sa distribution de probabilité.

Loi de la moyenne empirique $\overline{X_n}$

Espérance et variance de $\overline{X_n}$

Soit $X_1, \ldots, X_n$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant X d'espérance μ et d'écart-type σ. La moyenne empirique de n échantillons aléatoires est définie par :

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \quad \text{avec} \quad \mathbb{E}[\overline{X}_n] = \mu \quad \text{et} \quad \mathbb{V}[\overline{X}_n] = \frac{\sigma^2}{n}$$

En effet :

$$\begin{aligned} E[\overline{X_n}] &= E[\frac{1}{n}\sum_{i=1}^{n} X_i] \\ &= \frac{1}{n}.E[\sum_{i=1}^{n} X_i] \\ &= \frac{1}{n}.\sum_{i=1}^{n} E[X_i] = \frac{1}{n}.n.\mu = \mu \end{aligned}$$

Loi de la moyenne empirique $\overline{X_n}$

Et :

$$
\begin{aligned}
V[\overline{X_n}] &= V[\frac{1}{n}\sum_{i=1}^{n} X_i] \\
&= \frac{1}{n^2}.V[\sum_{i=1}^{n} X_i] \\
&= \frac{1}{n^2}.\sum_{i=1}^{n} V[X_i] \\
&= \frac{1}{n^2}.n.\sigma^2 = \frac{\sigma^2}{n}
\end{aligned}
$$

Pour déterminer la distribution de probabilité de $\overline{X}_n$, nous allons distinguer deux cas : celui des grands échantillons ($n \geq 30$) et celui des petits échantillons ($n < 30$).

Loi de la moyenne empirique $\overline{X_n}$

- **Cas des grands échantillons ($n \geq 30$)**

On commençe par annoncer le théorème fondamental suivant:

Le théorème central-limite (TCL)

Soit $X_1, \ldots, X_n$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant la loi de X d'espérance μ et d'écart-type σ.

Alors, pour n est assez grand ($n \geq 30$), $Y = \sum_{i=1}^{n} X_i$ suit une loi normale de moyenne $n\,\mu$ et d'écart-type $\sqrt{n}\,\sigma$.

$$Y \sim \mathcal{N}(n\,m, \sqrt{n}\,\sigma)$$

En appliquant le théorème central limite, la loi normale est une bonne approximation de la loi de $\overline{X}_n$:

Loi de la moyenne empirique $\overline{X_n}$

Proposition

Soit $X_1, \ldots, X_n$ une suite de variables aléatoires indépendantes et identiquement distribuées suivant X d'une loi quelconque d'espérance μ et d'écart-type σ. La moyenne empirique de n échantillons aléatoires est défini par :

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \quad \text{avec} \quad \mathbb{E}[\overline{X}_n] = \mu \quad \text{et} \quad \mathbb{V}[\overline{X}_n] = \frac{\sigma^2}{n}$$

De plus, quand n est assez grand($n \geq 30$),

$$\overline{X}_n \sim \mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}}) \quad \text{donc} \quad Z = \frac{\overline{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1)$$

Loi de la moyenne empirique $\overline{X_n}$

Remarque

Si la variance σ^2 est inconnue, il suffit de l'estimer par

$$s_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x_n})^2$$

On aura donc,

$$\overline{X}_n \sim \mathcal{N}(\mu, \frac{s_n}{\sqrt{n}}) \quad \text{donc} \quad Z = \frac{\overline{X}_n - \mu}{\frac{s_n}{\sqrt{n}}} \sim \mathcal{N}(0,1)$$

Loi de la moyenne empirique $\overline{X_n}$

Exemple

Soit un lot de 500 chocolats. Le poids d'un chocolat est une variable aléatoire d'espérance $\mu = 5g$ et de variance $\sigma^2 = 0.5g$.
Quelle est la probabilité qu'une boite de 50 chocolats issus de ce lot ait un poids moyen supérieur à $5.2g$?

Solution

On a $n = 50 > 30$, et $X \sim \mathcal{L}(\mu = 5; \sigma^2 = 0.5)$, alors par le TCL :

$$\overline{X_n} \sim \mathcal{N}(\mu\ ; \frac{\sigma}{\sqrt{n}})$$

Et par la suite :

$$Z = \frac{\overline{X_n} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

$$\begin{aligned}\mathbb{P}(\overline{X}_n \geq 5.2) &= \mathbb{P}(Z \geq \frac{5.2 - 5}{\sqrt{\frac{0,5}{50}}}) \\ &= \mathbb{P}(Z \geq 2) \\ &= 0.022\end{aligned}$$

(Lecture sur la table de la loi Normale).

Loi de la moyenne empirique $\overline{X_n}$

- **Cas des petits échantillons ($n < 30$)**

Nous nous plaçons alors exclusivement dans le cas où la population est normale: X suit une **loi normale** de moyenne m et de variance σ^2.
Nous allons encore distinguer deux cas : celui où σ est connu et celui où σ est inconnu.

σ connu:

Proposition

X suit une loi normale $\mathcal{N}(\mu;\sigma)$ donc les variables X_i suivent toutes la même loi que X, $\forall 1 \leq i \leq n$,

$$X_i \sim \mathcal{N}(\mu;\sigma) \text{ alors } \overline{X}_n \sim \mathcal{N}(\mu;\frac{\sigma}{\sqrt{n}}) \text{ donc } Z = \frac{\overline{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1)$$

Loi de la moyenne empirique $\overline{X_n}$

Exemple

Le responsable d'une entreprise a accumulé depuis des années les résultats à un test d'aptitude à effectuer un certain travail. Les résultats au test d'aptitude sont distribués suivant une loi normale de moyenne égale 150 et de variance 100. On fait passer le test à 25 individus de l'entreprise. Quelle est la probabilité que la moyenne de l'échantillon soit entre 146 et 154 ?

Solution

On a $n = 25 < 30$, et $X \sim \mathcal{N}(\mu = 150; \sigma^2 = 100)$, alors :

$$\overline{X_n} \sim \mathcal{N}(\mu; \frac{\sigma}{\sqrt{n}})$$

Et par la suite :

$$Z = \frac{\overline{X_n} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

$$\begin{aligned}
\mathbb{P}(146 \leq \overline{X_n} \leq 154) &= \mathbb{P}(\frac{146 - 150}{\frac{10}{\sqrt{25}}} \leq Z \leq \frac{154 - 150}{\frac{10}{\sqrt{25}}}) \\
&= \mathbb{P}(-2 \leq Z \leq 2) \\
&= 1 - \mathbb{P}(Z \geq 2) - \mathbb{P}(Z \geq 2) \\
&= 1 - 2\mathbb{P}(Z \geq 2) = 1 - 2.(0.022) = 0.956
\end{aligned}$$

(Lecture sur la table de la loi Normale)

Loi de la moyenne empirique $\overline{X_n}$

σ inconnu:

La variance σ^2 est inconnue, il suffit d'utiliser l'estimateur :

$S_n^2 = \dfrac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X_n})^2$ d'estimation : $s_n^2 = \dfrac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x_n})^2$

Proposition

Dans le cas où σ est inconnu, nous allons utiliser la statistique définie par:

$$T = \frac{\overline{X}_n - \mu}{\frac{S_n}{\sqrt{n}}} \sim \mathcal{T}_{(n-1)} \text{ la loi de Student de } (n-1) \text{ degrés de liberté .}$$

Pour le cas $n < 30$ et la loi $\mathbb{P}$ est quelconque alors le TCL ne s'applique pas et on ne peut pas déduire la loi de $\overline{X}_n$.

Loi de la moyenne empirique $\overline{X_n}$

Exemple

On détecte que l'âge auquel apparaissent les premiers mots de vocabulaire chez l'enfant suit une loi normale de moyenne 12 mois et de variance inconnue. On prend un échantillon de taille 25 alors donner la probabilité que l'âge moyen dans l'échantillon soit supérieur ou égal à 14 mois sachant que la variance sur l'échantillon est égale à $12,8$ mois.

Solution

On a $n = 25 < 30$, et $X \sim \mathcal{N}(\mu = 12; \sigma^2 = ?)$, et la variance mesurée sur l'échantillon est $s_n^2 = 12.8$, alors la statistique :

$$T = \frac{\overline{X_n} - \mu}{\frac{S_n}{\sqrt{n}}} \sim \mathcal{T}_{n-1}$$

$$\begin{aligned}
\mathbb{P}(\overline{X_n} \geq 14) &= \mathbb{P}(T \geq \frac{14 - 12}{\sqrt{\frac{12.8}{25}}}) \\
&= \mathbb{P}(T \geq 2.79) \quad , \quad T \sim \mathcal{T}_{24} \\
&= 0.005,
\end{aligned}$$

(lecture de la table de la loi de student à 24 ddl)

Loi de la moyenne empirique $\overline{X_n}$

Conclusion La loi de la moyenne empirique $\overline{X_n}$ est donnée par ce tableau récapitulatif :

$n \geq 30$ & **Population de loi quelconque de moyenne m et de variance σ^2**		
Variance σ^2	$\overline{X_n}$	**Ecart réduit**
connue	$\overline{X_n} \sim \mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}})$	$Z = \frac{\overline{X_n} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1)$
inconnue, on utilise l'estimation $s_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x_n})^2$	$\overline{X_n} \sim \mathcal{N}(\mu, \frac{s_n}{\sqrt{n}})$	$Z = \frac{\overline{X_n} - m}{\frac{s_n}{\sqrt{n}}} \sim \mathcal{N}(0,1)$
$n < 30$ & **Population normale de moyenne μ et de variance σ^2**		
Variance σ^2	$\overline{X_n}$	**Ecart réduit**
connue	$\overline{X_n} \sim \mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}})$	$Z = \frac{\overline{X_n} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1)$
inconnue, on utilise l'estimateur $S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X_n})^2$	$T = \frac{\overline{X_n} - \mu}{\frac{S_n}{\sqrt{n}}} \sim T_{n-1}$	$T_{n-1} \sim$ Student de $(n-1)$ ddl

Distribution échantillonnale de la variance S_n^2

Distribution échantillonnale de la variance S_n^2:

Nous nous plaçons alors exclusivement dans le cas où la population est normale: X suit une **loi normale** de moyenne μ et de variance σ^2. On appelle variance empirique, la statistique notée S_n^2, on cherhce à caractériser S_n^2. Nous allons distinguer deux cas : celui où m est connue et celui m est inconnue.

Proposition : μ connue

Soit $X_1, \ldots, X_n$ un échantillon aléatoire d'une variable aléatoire X qui suit une loi normale $\mathcal{N}(\mu, \sigma)$. Soit la variance échantillonnale S_n^2 définie par:

$$S_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2 \quad \text{avec} \quad \mathbb{E}(S_n^2) = \sigma^2$$

$$\Longrightarrow Y = \frac{n\, S_n^2}{\sigma^2} \sim \chi_n^2 \quad \text{suit une loi de Khi-deux avec } n \text{ degrés de liberté}$$

Distribution échantillonnale de la variance S_n^2

Exemple

Une étude a montré que le taux des chômeurs tunisiens suit une loi normale d'espérance $\mu = 20$ et de variance $\sigma^2 = 42,67$. Un échantillon de taille 25 a été prélevé, alors donner la probabilité que la variance moyenne des chômeurs soit supérieur où égale à 22.39.

Distribution échantillonnale de la variance S_n^2

Solution

On a $n = 25$, et $X \sim \mathcal{N}(\mu = 20; \sigma^2 = 42.67)$, alors la statistique :

$$Y = \frac{n.S_n^2}{\sigma^2} \sim \chi_n^2$$

$$\begin{aligned}
\mathbb{P}(S_n^2 \geq 22.39) &= \mathbb{P}(\frac{n.S_n^2}{\sigma^2} \geq \frac{22.39 \times 25}{42.67}) \\
&= \mathbb{P}(Y \geq 13.12) \quad , \quad Y \sim \chi_{25}^2 \\
&= 0.975
\end{aligned}$$

(lecture de la table de la loi χ_{25}^2)

Distribution échantillonnale de la variance S_n^2

Proposition : m inconnue

Soit $X_1, \ldots, X_n$ un échantillon aléatoire d'une variable aléatoire X qui suit une loi normale $\mathcal{N}(\mu, \sigma)$. Soit la variance échantillonnale S^2 définie par:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X}_n)^2 \quad \text{avec} \quad \mathbb{E}(S_n^2) = \sigma^2$$

On a,

$$Y = \frac{(n-1)\, S_n^2}{\sigma^2} \quad \text{suit une loi du Khi-deux avec } (n-1) \text{ degrés de liberté}$$

Distribution échantillonnale de la variance S_n^2

Exemple

On fait l'hypothèse que la taille (en cm) des 3000 étudiants masculins d'ESPRIT est une variable aléatoire distribuée normalement de moyenne inconnue et de variance 100. Un échantillon de taille 25 est sélectionné de cette population. Quelle est la probabilité que la variance échantillonnale S_n^2 soit au plus égale 151,72 ?

Distribution échantillonnale de la variance S_n^2

Solution

On a $n = 25$, et $X \sim \mathcal{N}(\mu = ?; \sigma^2 = 100)$, alors la statistique :

$$Y = \frac{(n-1)S_n^2}{\sigma^2} \sim \chi^2_{n-1}$$

$$\begin{aligned}
\mathbb{P}(S_n^2 \leq 151.72) &= \mathbb{P}\left(\frac{(n-1)S_n^2}{\sigma^2} \leq \frac{151.72 \times (25-1)}{100}\right) \\
&= \mathbb{P}(Y \leq 36.41) \quad , \quad Y \sim \chi^2_{24} \\
&= 1 - \mathbb{P}(Y \geq 36.41) \\
&= 1 - 0.05 = 0.95
\end{aligned}$$

(lecture de la table de la loi χ^2_{24})

Distribution échantillonnale de la variance S_n^2

Conclusion La loi de la variance empirique S_n^2 est donnée par ce tableau récapitulatif :

Cas possibles	S_n^2 estimateur de σ^2	Ecart réduit
μ connue	$S_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2$	$Y = \frac{n.S_n^2}{\sigma^2} \sim \chi_n^2$
μ inconnue, $\overline{X_n} = \frac{1}{n}\sum_{i=1}^{n} X_i$	$S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X_n})^2$	$Y = \frac{(n-1)S_n^2}{\sigma^2} \sim \chi_{n-1}^2$

Disribution échantillonnale de la proportion F

Soit $X_1, \ldots, X_n$ un échantillon aléatoire, tel que $X_i \sim \mathcal{B}(p)$, $\forall\, 1 \leq i \leq n$. Soit F la fréquence d'apparition d'un caractère qualitatif dans un échantillon de taille n, donc

$$F = \frac{X}{n} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

où X est le nombre de fois où le caractère apparaît dans l'échantillon de taille n. Par définition X suit $\mathcal{B}(n; p)$.

$$X \sim \mathcal{B}(n; p) \qquad \text{avec} \qquad E[X] = np \quad \text{et} \quad V[X] = np(1-p)$$

Disribution échantillonnale de la proportion F

Proposition

Soit $X_1, \ldots, X_n$ un échantillon aléatoire, telque $X_i \sim \mathcal{B}(p)$, $\forall\ 1 \leq i \leq n$, donc

$$F = \frac{1}{n}\sum_{i=1}^{n} X_i \quad \text{avec} \quad E[F] = p \qquad \text{et} \qquad V[F] = \frac{p(1-p)}{n}$$

Si $n \geq 30$, $np \geq 5$ et $n(1-p) \geq 5$, alors,

$$F \sim \mathcal{N}(p, \sqrt{\frac{p(1-p)}{n}}) \quad \text{et} \quad Z = \frac{F-p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1)$$

Disribution échantillonnale de la proportion F

Proposition

1. L'espérance de la fréquence d'échantillon est égale à la probabilité théorique d'apparition dans la population.
2. Lorsque la taille de l'échantillon augmente, la variance de F diminue, ce qui est logique: plus on a d'informations, plus il est probable que la proportion observée dans l'échantillon soit proche de la proportion de la population.

Disribution échantillonnale de la proportion F

Exemple

Une étude affirme que 30% des citoyens de la population tunisienne effectuent régulièrement des achats en ligne. Prenons alors un échantillon de 100 personnes, quelle est la probabilité qu'au moins 40% parmi ces interrogés font des achats en ligne?

Disribution échantillonnale de la proportion F

Solution

En utilisant le résultat ci-dessus, (hypothèse $n > 30$, $np > 5$ et $n(1-p) > 5$ est déjà vérifiée), on a :

$$\begin{aligned}\mathbb{P}(F \geq 0,4) &= \mathbb{P}\left(\frac{F-p}{\sqrt{\frac{p(1-p)}{n}}} \geq \frac{0,4-0,3}{\sqrt{\frac{0,3\times 0,7)}{100}}}\right)\\ &= \mathbb{P}\left(\frac{F-p}{\sqrt{\frac{p(1-p)}{n}}} \geq 2,18\right)\\ &= 0,01463\end{aligned}$$

(Selon la table $\mathcal{N}(0,1)$) .

Disribution échantillonnale de la proportion F

Conclusion La loi de la variance empirique F est donnée par ce tableau récapitulatif :

$n \geq 30 \quad \& \quad np \geq 5 \quad \& \quad nq = n(1-p) \geq 5$	
Loi de F	**Ecart réduit**
$F \sim \mathcal{N}(p, \sqrt{\frac{p(1-p)}{n}})$	$Z = \frac{F-p}{\sqrt{\frac{p(1-p)}{n}}} \sim \mathcal{N}(0,1)$